Tecniche di Machine Learning e Deep Learning per la Predizione dei Fattori di Rischio del Tumore Cervicale

Apprendimento Automatico e Apprendimento Profondo
Elaborato Progettuale

Università San Raffaele Roma
Ingegneria Informatica e dell'Intelligenza Artificiale Applicata (LM-32)

Candidato: Daniele Iodice **Matricola:** 0322500045
Anno Accademico: 2025/2026

Link Dataset: `https://doi.org/10.24432/C5Z310`

Link Repository Studente:
`https://github.com/danieleiodice/AAAP_progetto`

1 Introduzione

Nel seguente elaborato è stato analizzato il dataset *Cervical Cancer (Risk Factors)*, reso disponibile da K. Fernandes, J. Cardoso e J. Fernandes presso l'UCI Machine Learning Repository (2017). I dati sono stati raccolti presso l'Hospital Universitario de Caracas, in Venezuela, con lo scopo di analizzare i fattori di rischio associati al tumore cervicale.

Il dataset è di tipo multivariato, ed è composto da 858 istanze (numero dei pazienti) descritte da 36 feature, le quali rappresentano dati demografici e anamnestici, abitudini personali e presenza di infezioni o patologie pregresse.

Sono presenti 4 variabili target, ciascuna delle quali rappresenta l'esito di un diverso esame diagnostico (`Biopsy, Hinselmann, Schiller, Cytology`).

2 Fasi introduttive

Dopo aver importato le librerie necessarie, è stato caricato il dataset. Data la presenza di più variabili predittive e più possibili target, è stata selezionata una singola incognita da predire (`Biopsy`), dopodiché sono state effettuate alcune operazioni fondamentali.

2.1 Preprocessing dei dati

Durante l'indagine, alcuni pazienti hanno scelto di non rispondere a determinate domande per motivi di privacy, determinando la presenza di valori mancanti nel dataset.

Per gestire correttamente questi casi, sono state applicate le seguenti fasi di preprocessing.

1. Sostituzione dei valori `?` con `NaN`.
2. Conversione delle feature in formato numerico `float`, necessaria per l'applicazione della standardizzazione e della PCA.
3. Riempimento dei valori mancanti con la mediana della rispettiva colonna.
4. Rimozione delle colonne costanti, che non apportano informazioni utili.

È stata preferita la mediana ad altre metriche in quanto più robusta agli outlier e meno impattante sulla distribuzione dei dati.

2.2 Matrice di correlazione

Per analizzare le relazioni tra le feature numeriche è stata calcolata la matrice di correlazione usando il coefficiente di Pearson (**Figura 1**). Dalla matrice si osserva un'assenza di correlazioni forti tra la maggior parte delle feature; ciò indica che le variabili sono perlopiù indipendenti tra loro.

2.3 Standardizzazione delle feature

L'operazione di standardizzazione delle feature mediante `StandardScaler` è fondamentale per l'applicazione dell'algoritmo di PCA, poiché garantisce che tutte le feature contribuiscano in modo equilibrato alla determinazione delle direzioni di massima varianza.

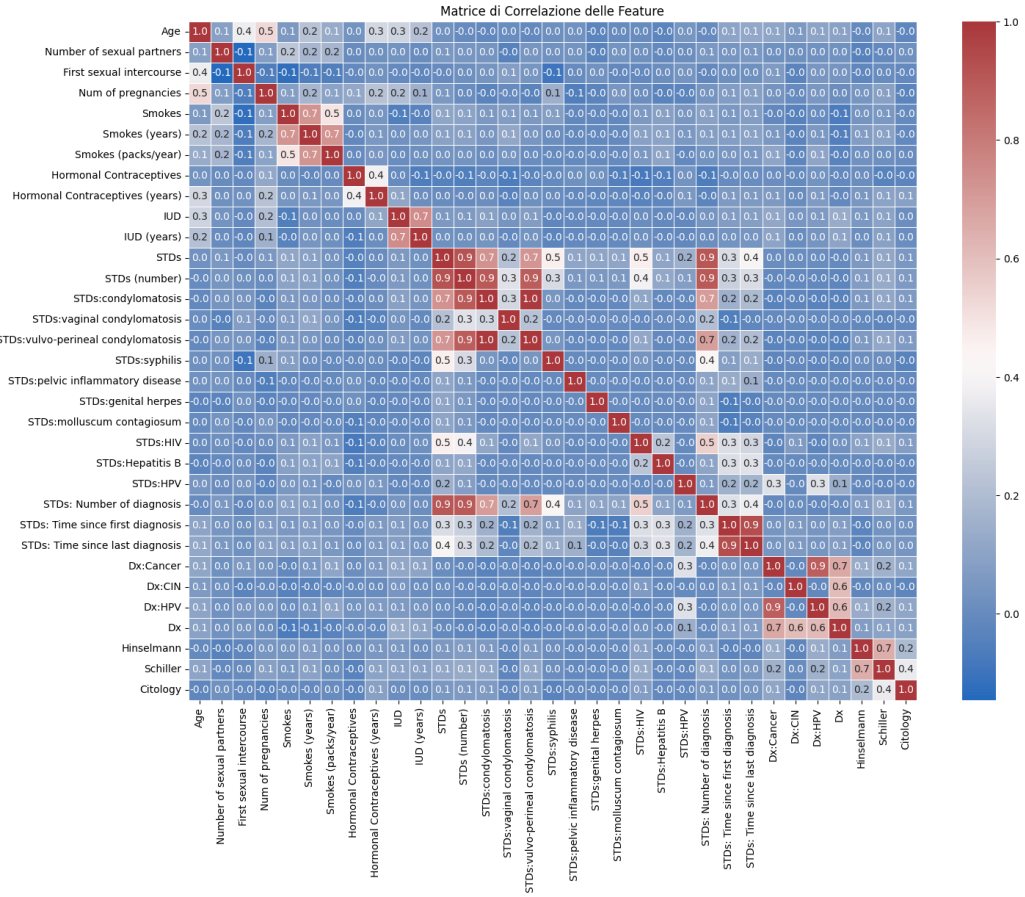

Figura 1: Matrice di correlazione tra le feature del dataset *Cervical Cancer*.

3 Analisi delle feature mediante PCA

In seguito è stata applicata la Principal Component Analysis (PCA) per ridurre la dimensionalità del dataset a due componenti principali, attraverso le seguenti operazioni.

1. Calcolo delle direzioni di massima varianza e proiezione dei dati nello spazio definito dalle componenti principali.

2. Conversione dei dati trasformati in un DataFrame Pandas, al quale è stata aggiunta la colonna Target.

3. Rappresentazione grafica della proiezione dei dati sulle prime due componenti principali della PCA mediante scatter plot, e calcolo della percentuale di varianza riportata (**Figura 2**).

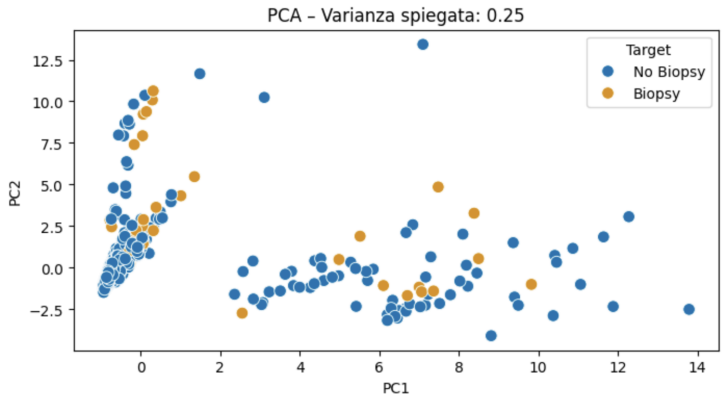

Figura 2: Proiezione dei dati sulle prime due componenti principali.

Le prime due componenti principali spiegano solo una parte limitata della varianza totale, indicando che i dati hanno una struttura complessa e che sono necessarie più componenti per rappresentare la maggior parte dell'informazione.

È stato inoltre realizzato uno scree plot (**Figura 3**), che mostra la varianza cumulativa spiegata da tutte le componenti principali e permette di valutare quante componenti siano sufficienti per rappresentare la maggior parte dell'informazione.

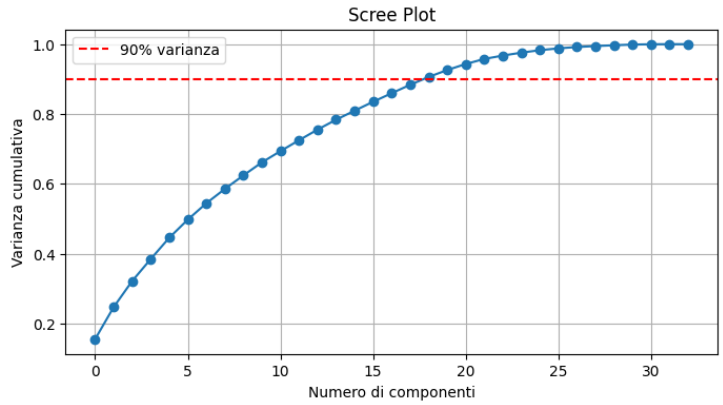

Figura 3: Scree plot per la selezione del numero di componenti principali.

4 Valutazione dei modelli di classificazione

Dopo aver preparato e standardizzato i dati, il dataset è stato suddiviso in set di addestramento e di test. Sono stati quindi addestrati diversi modelli di classificazione per predire il target, e le loro prestazioni sono state valutate.

Gaussian Naïve Bayes

Il `GaussianNB` mostra prestazioni scarse, con accuracy pari al 9.3% e F1-score molto basso, dovuti a una forte distorsione delle predizioni verso la classe minoritaria.

Tuttavia, dalla ROC AUC (0.84) si osserva che il modello mantiene una discreta capacità di distinguere tra le due classi in termini probabilistici.

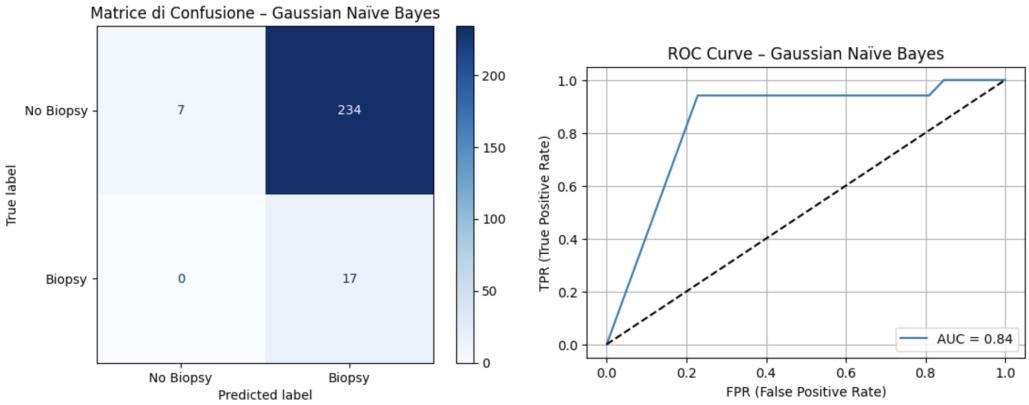

Figura 4: Gaussian Naïve Bayes – Matrice di confusione e curva ROC.

Regressione Logistica

La Logistic Regression ottiene buone prestazioni complessive, con accuracy pari al 94.2% e ROC AUC pari a 0.93.

Il modello mostra un buon compromesso tra precisione e recall sulla classe minoritaria `Biopsy`, risultando efficace sebbene il dataset sia sbilanciato.

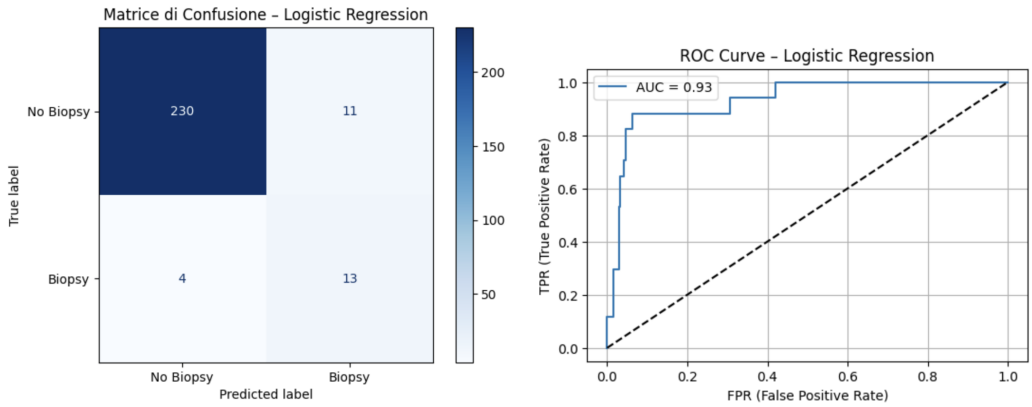

Figura 5: Logistic Regression – Matrice di confusione e curva ROC.

SVM (Support Vector Machine)

Il classificatore SVM raggiunge prestazioni simili alla regressione logistica (accuracy 93.8%, ROC AUC 0.94).

Tuttavia, il recall sulla classe `Biopsy` (0.59) risulta inferiore rispetto alla regressione logistica (0.76), nonostante la maggiore complessità del modello.

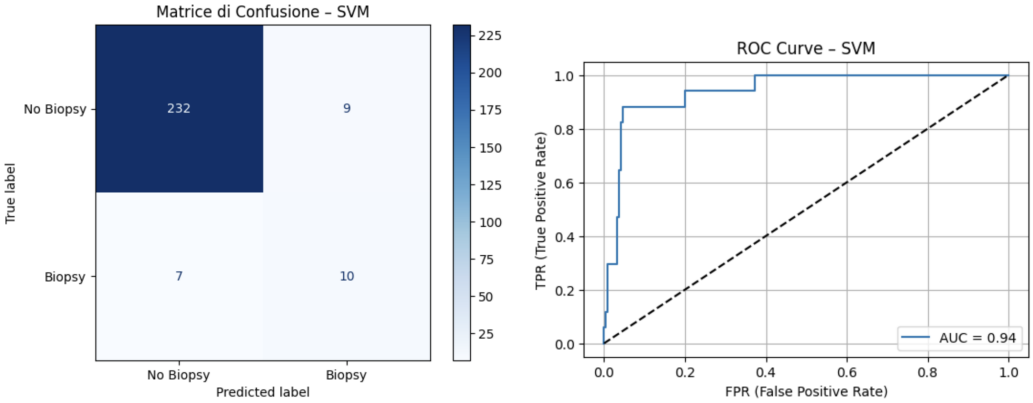

Figura 6: SVM – Matrice di confusione e curva ROC.

Random Forest

La Random Forest ottiene il valore più elevato di ROC AUC tra i modelli analizzati (0.96), indicando un'eccellente capacità discriminativa.

L'accuracy complessiva è pari al 94.6%, ma il recall sulla classe `Biopsy` è pari a 0.41; dunque, il modello tende a privilegiare la classe maggioritaria.

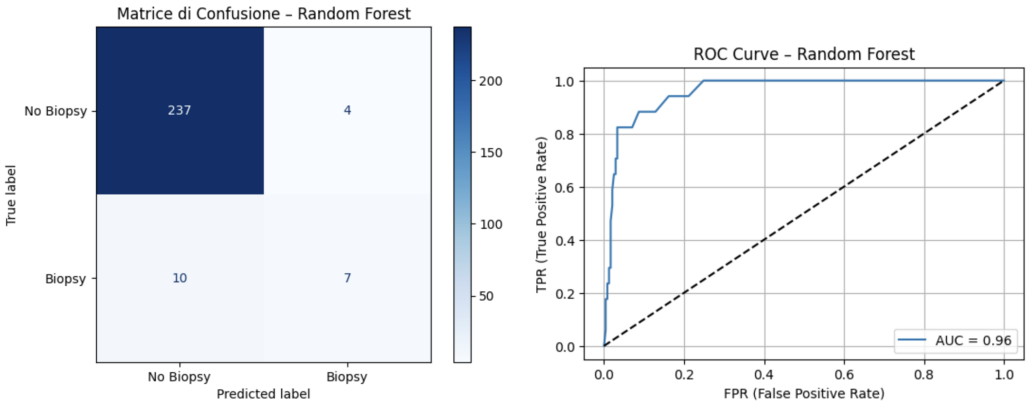

Figura 7: Random Forest – Matrice di confusione e curva ROC.

Per il classificatore Random Forest è stata anche calcolata l'importanza della singola feature, rappresentata mediante un istogramma.

5 Deep Learning

Per confrontare i modelli di classificazione tradizionali con un approccio basato su reti neurali, è stata implementata una rete neurale artificiale feed-forward adottando il framework TensorFlow/Keras.

Si è definita una rete neurale con la seguente struttura:

- un layer di input con dimensione pari al numero di feature;
- un layer denso nascosto con 16 neuroni e funzione di attivazione `ReLU`;
- un layer di output con funzione di attivazione `sigmoid`.

Il modello è stato addestrato utilizzando l'ottimizzatore `Adam` e la funzione di perdita `binary cross-entropy`. Durante l'addestramento è stato utilizzato il 20% del training set come validation set e sono stati monitorati andamento della loss e dell'accuracy tramite `TensorBoard`.

Valutazione delle prestazioni

Il modello presenta accuracy e ROC AUC alte (93.4% e 0.94 rispettivamente) e, al contempo, una recall sulla classe minoritaria comparabile a quella ottenuta da regressione logistica e SVM.

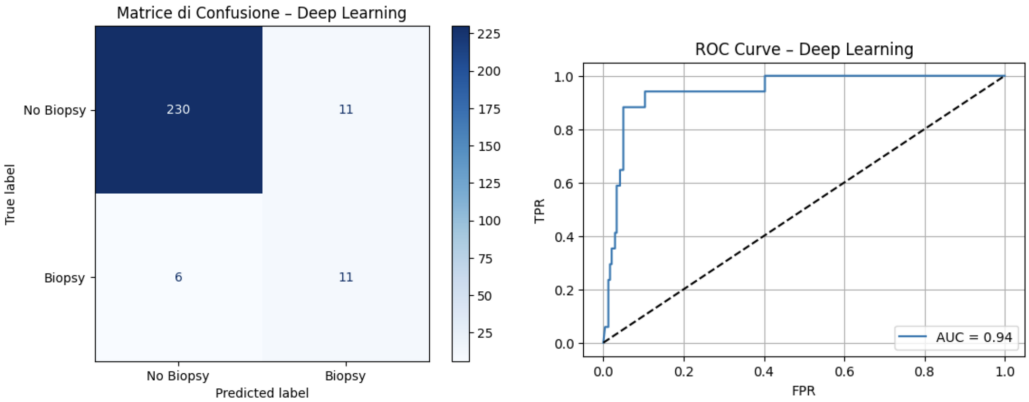

Figura 8: Rete Neurale – Matrice di confusione e curva ROC.

Nonostante ciò, le prestazioni ottenute non migliorano in maniera significativa; di conseguenza, per il dataset studiato l'utilizzo di reti neurali non fornisce vantaggi sostanziali rispetto a metodi di classificazione più semplici.